

# New analysis method of TPC data using neural network

Takanobu Doi<sup>1</sup>, Takahiro KAWABATA<sup>2</sup>, Tatsuya FURUNO<sup>3</sup>, Yuki FUJIKAWA<sup>1</sup>, Kento INABA<sup>1</sup>,  
Motoki MURATA<sup>3</sup>, Shintaro OKAMOTO<sup>1</sup> and Akane SAKAUE<sup>1</sup>

<sup>1</sup>Department of Physics, Kyoto University, Kyoto, Kyoto 606-8502, Japan

<sup>2</sup>Department of Physics, Osaka University, Toyonaka, Osaka 540-0043, Japan

<sup>3</sup>Research Center for Nuclear Physics, Osaka University, Ibaraki, Osaka 567-0047, Japan

E-mail: doi.takanobu.68x@st.kyoto-u.ac.jp

(Received 2019/8/4)

TPC を用いた実験では荷電粒子の軌跡を 3 次元的に測定することができる。従来は Hough 変換を用いてデータの解析を行って来た。この方法を用いた解析には多くの労力を要する。近年、画像データの認識にはニューラルネットワークが注目されている。本研究では、新しくニューラルネットワークを用いた解析方法の開発を行った。新しく開発した手法を用いることで、従来の方法と比較して高速に解析できるようになった。

**KEYWORDS:** neural networks, convolutional neural networks, TPC, active target, MAIKo TPC

## 1. Introduction

近年、荷電粒子の飛跡を測定する検出器として Time Projection Chamber (TPC) が多く用いられている。検出器にガスを充填しておき、荷電粒子がガス中を通過するとき発生する電子をドリフト電場により読み出し面にドリフトさせることで飛跡を検出する。TPC は 2 次元的に位置を決定することが出来る読み出し機構を用いることで平面的な飛跡を決定し、飛跡が通った信号が読み出し機構に到達するまでの時間を測定することで、3 次元的に飛跡の位置を決定することが出来る。TPC から得られる画像データから飛跡情報を抽出には多くの労力が必要となる。そこで、我々は近年画像認識において多くの成果を出しているニューラルネットワークを用いることで、より高速な解析を行うことができる解析方法の開発を行った。

## 2. What is MAIKo TPC

我々は不安定核実験に用いるために Micro Pixel Chamber ( $\mu$ -PIC) [1] で読み出しを行う TPC とアクティブ標的を用いた、Mu-Pic based Active target for Inverse Kinematics . (MAIKo) TPC [2] (Fig. 1) を不安定核実験に用いるために開発した。アクティブ標的とは検出ガスを実験の標的として用いることである。この手法を用いることで大立体角で低エネルギー粒子の測定を行うことが出来る。標的として用いるガスだけではドリフト電場を作る際に放電する可能性があり、放電を防ぐためにクエンチガスを混ぜて運用する。標的以外のガスが混ざるため、目的の粒子以外との散乱事象も測定される。

MAIKo TPC の大きさは 102.4 mm (W)  $\times$  102.4 mm (D)  $\times$  140.0 mm (H) である。 $\mu$ -PIC は直交する 2 種類のストリップを用いて信号を読み出すため、荷電粒子の飛跡は 2 つの 2 次元画像の組として得られる。 $\mu$ -PIC のストリップは 400  $\mu$ m 間隔で 256 本ある。時間方向は 100 MHz で 1024 sample 測定する。そのため、MAIKo




Fig. 1. MAIKo TPC の外観。

TPC は  $256 \times 1024$  pixels の z-y 平面と x-y 平面に射影された 2 つの画像が得られる。

近年、大阪大学核物理研究センター (RCNP) において、 $\mu$ -PIC は直交する 2 種類のストリップを用いて読み出しを行うため、MAIKo TPC を用いた  $^{10}\text{C}$  と  $^4\text{He}$  の非弾性散乱の測定が初めて行われた。標的ガスとして He、クエンチガスとして  $\text{CO}_2$  を用いた。MAIKo TPC からは Fig. 2, 3 に示すような飛跡データが得られる。MAIKo TPC では標的である  $^4\text{He}$  との散乱事象以外にもクエンチガスに含まれる C や O との散乱も測定される。

散乱実験では、散乱粒子のエネルギーと放出角度を決定する必要がある。散乱粒子のエネルギーは、散乱粒子がガス中で停止するまでの距離から決定することが出来る。飛跡情報の抽出を行うためには

- 標的との散乱事象と背景事象との識別
- 飛跡の長さや方向などの物理的情報の抽出

の大きくわけて 2 つの解析が必要になる。




Fig. 2.  $^{10}\text{C} + ^4\text{He}$  の散乱事象




Fig. 3.  $^{10}\text{C}$  とクエンチガスとの散乱事象

### 3. Conventional analysis method

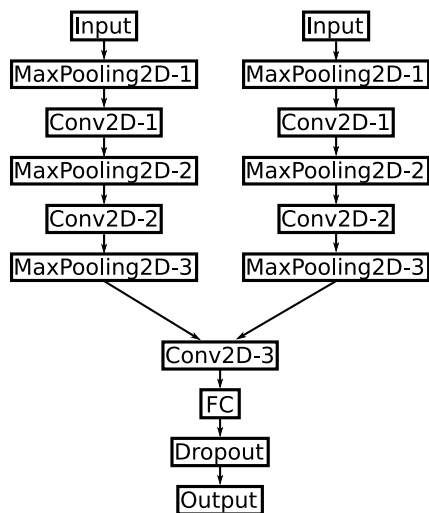
従来は、MAIKo TPC から得られるデータから背景事象の除去を画像から直線を抽出する方法の 1 つである Hough 変換を用いたアルゴリズムによって行ってきた。Hough 変換を行うことで画像は、原点からの距離 ( $r$ ) と傾き ( $\theta$ ) の 2 つの軸を持つパラメータ空間に変換される。このパラメータ空間において複数の曲線が交わる点を求めれば  $r$  と  $\theta$  が一意に決定され、元の画像における直線を抽出することができる。抽出した直線に沿って端点を探すことで、画像に含まれる直線の方法や長さなどを決定することができる。これらの情報に対して多くの条件を課すことで画像の識別を行う。この条件を設定するには多くのパラメータを必要とし、分岐条件も複雑なものとなる。そのため、パラメータの最適化や画像識別に多くの時間を必要とする。

パラメータ最適化には 100 CPU を使用して約 1 日かかり、その後の識別には 1 イベントあたり 1 秒かかった。最適化を行ったあとの画像識別の結果を Table ?? に示す。この手法による識別能力の評価には、画像データを人間が目で見ても散乱事象もしくは背景事象と判断した 3000 イベントを評価用データとして用いて行った。全イベントのうち、散乱事象または背景事象と正しく判断することが出来た割合を正解率としたとき、この従来型の解析手法では 89% であった。

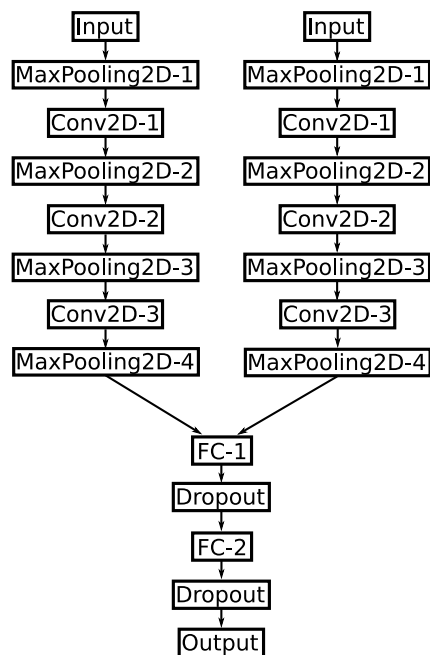
### 4. New analysis method

従来手法では識別に複雑な分岐条件が必要になるなどの問題点があった。そこで、我々は近年注目されているニューラルネットワークを用いることで、これらの問題点克服する新しい解析方法の開発を試みた。ニューラルネットワークを用いることで、複雑な条件分岐を導入する

ことなく、直線の位置、角度などの従来の解析手法ではまとめて扱うことの難しい画像に含まれる多くの特徴量を同時に考慮した画像識別が可能になると期待される。また、ニューラルネットワークは一度構築するとその後は短時間で画像識別を行うことができる。このようなニューラルネットワークの特徴を活かすことで、従来のアルゴリズムでは実現が難しかった高い精度と短い識別時間を実現することが可能である。



**Fig. 4.** データの選別を行うためのニューラルネットワーク



**Fig. 5.** 画像から情報を抽出するためのニューラルネットワーク

MAIKo TPC から得られるデータが画像であるため、画像認識に有用である Convolutional Neural Network (CNN) を用いた。CNN とはネットワーク内に畳み込み層を有するネットワーク構造である。解析には事象の選別と軌跡情報の抽出の2つの段階があるため、2種類のニューラルネットワークを用いて解析を行った。事象の選別を行うニューラルネットワークと画像から情報を抽出するニューラルネットワークの構造をそれぞれ Fig. 4 と Fig. 5 に示す。

事象選別のためのニューラルネットワークは、MAIKo TPC から得られる2つの平面に射影された飛跡画像を入力し、その事象が標的と散乱した事象である確率を出力する。出力された確率がある値以上である場合にその事象を標的と散乱した事象であると判断する。このネットワークは16層からなり、2入力1出力の形をしている。側面に射影した飛跡とビーム方向に射影した飛跡とでは画像の持つ意味が異なるため、2つの入力に別れた構造を持つネットワークを構築した。人間が判断したデータを用いて、学習および評価を行った。学習には2,700 events、評価には300 eventsを使用した。

飛跡情報を抽出するためのネットワークは、MAIKo TPC から得られる2つの平面に射影された飛跡画像を入力し、散乱が起こった座標と反跳した $^4\text{He}$ が停止した座標を出力する。教師データには従来手法で決定した座標を用いた。学習には3,012 events、評価には1,554 eventsを使用した。

学習環境はIntel Core i7、Nvidia GeForce GTX 1080Ti、Ubuntu 18.04 LTS、TensorFlow [3]+Keras [4]を用いた。

## 5. Result

選別のためのニューラルネットワークは、2,700 events に対して 200 回学習を行った。学習にはおよそ 26 分、その後の推測にはおよそ 1 秒かかった。従来手法の評価に用いた実験データのうち、300 イベントを用いて評価を行った結果、正解率は 96% であった。従来の手法と比較してすべての指標においてより高精度に選別が可能となった。また、パラメータチューニングおよび選別に要する時間も大きく短縮することができた。

座標の決定のためのニューラルネットワークは、3,012 events に対して 500 回学習を行った。学習にはおよそ 270 分、その後の推測にはおよそ 2 秒かかった。学習後にニューラルネットワークが予測した座標と従来手法によって決定した座標の比較を Fig. 6 に示す。

赤色の点は散乱が起こった点、緑色は反跳粒子が停止した点を表す。丸点は従来型の手法を用いて決定した点 (学習に用いたデータ)、バツ点はニューラルネットワークを用いて決定した点を表す。従来手法の精度を維持しつつ、従来の手法と比較してパラメータチューニングおよび情報の抽出にかかる時間を短縮することができた。

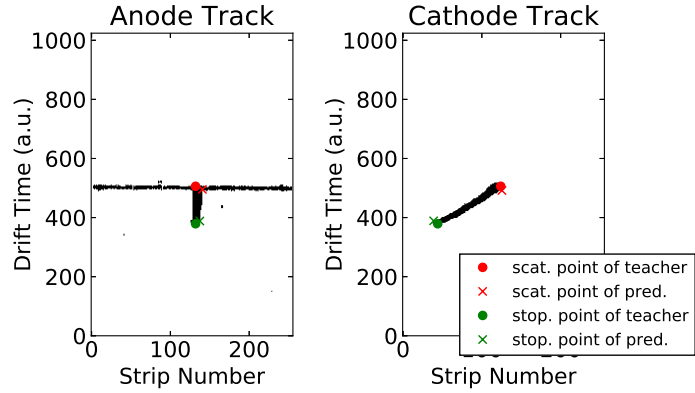


Fig. 6. ニューラルネットワークによって決定した座標と Hough 変換によって決定した座標との比較

## 6. Conclusion

従来の Hough 変換を用いた画像識別アルゴリズムに変わる、ニューラルネットワークを用いた新手法の開発を行った。新手法は従来のものよりも高速かつ高精度に画像を識別することが可能となった。また、飛跡情報の抽出については従来の精度を保ちつつ、高速に行うことが可能となった。ニューラルネットワークを用いた解析手法は TPC の解析に有用であることがわかった。

## References

- [1] A. Ochi, T. Nagayoshi, T. Tanimori, T. Nagae, and M. Nakamura Nuclear Instruments and Methods in Physics Research A **471** 264 (2001)
- [2] T. Furuno, T. Kawabata, H. Ong, S. Adachi, Y. Ayyad, T. Baba, Y. Fujikawa, T. Hashimoto, K. Inaba, Y. Ishii, S. Kabuki, H. Kubo, Y. Matsuda, Y. Matsuoka, T. Mizumoto, T. Morimoto, M. Murata, T. Sawano, T. Suzuki, A. Takada, J. Tanaka, I. Tanihata, T. Tanimori, D. Tran, M., Tsumura, and H. Watanabe Nuclear Instruments and Methods in Physics Research A **908** 215 (2018)
- [3] A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas, O. Vinyals, P. Warden, M. Wattenberg, M. Wicke, Y. Yu, and X. Zheng, (2015). <https://tensorflow.org>
- [4] F. Chollet, et al. (2015). <https://keras.io>