

New analysis method of TPC data using neural network

Takanobu Doi¹, Takahiro KAWABATA², Tatsuya FURUNO³, Yuki FUJIKAWA¹, Kento INABA¹,
Motoki MURATA³, Shintaro OKAMOTO¹ and Akane SAKAUE¹

¹Department of Physics, Kyoto University, Kyoto, Kyoto 606-8502, Japan

²Department of Physics, Osaka University, Toyonaka, Osaka 540-0043, Japan

³Research Center for Nuclear Physics, Osaka University, Ibaraki, Osaka 567-0047, Japan

E-mail: doi.takanobu.68x@st.kyoto-u.ac.jp

(Received)

KEYWORDS: neural networks, TPC, MAIKo

1. Introduction

近年、不安定核を用いた原子核実験において検出ガスを標的として用いるアクティブ標的が多く用いられている。また、荷電粒子の飛跡を2次元的に検出することができる Time Projection Chamber (TPC) が多く用いられている。TPC は大きな立体角を覆うことができ、多くの物理量を同時に測定することが可能である。このアクティブ標的を用いた TPC のデータ解析において、背景事象となるデータの選別や飛跡データの物理的情報の抽出には多くの労力が必要となる。そこで、我々は近年画像認識において多くの成果を出しているニューラルネットワークを用いることで、より効率的な解析を行うことができる解析方法の開発を行った。

2. What is MAIKo TPC

我々は Micro Pixel Chamber (μ -PIC) [1] で読み出しを行う TPC とアクティブ標的を用いた検出器である Mu-Pic based Active target for Inverse Kinematics . (MAIKo) TPC [2] (Fig. 1) を不安定核実験に用いるために開発した。MAIKo TPC の大きさは 102.4mm(W)×102.4mm(D)×140.0mm(H) である。MAIKo TPC では飛跡を3次元情報として取得せず、側面方向とビーム入射方向の2つの平面へ射影した飛跡として得られる。それぞれの画像は 256×1024 pixels で得られる。

近年、大阪大学核物理研究センター (RCNP) において、MAIKo TPC を用いた ^{10}C と ^4He の非弾性散乱の測定が初めて行われた。MAIKo TPC からは Fig. 2, 3 に示すような飛跡データが得られる。各図ともに左図が側面に射影した飛跡、右図がビーム方向に射影した飛跡を示す。MAIKo TPC では標的である ^4He との散乱事象以外にもクエンチガスの C や O との散乱も測定される。飛跡情報の抽出を行うためには背景事象と標的との散乱事象との識別を行わなければならない。その後に飛跡の長さや方向などの物理的情報の抽出を行う。




Fig. 1. MAIKo TPC の外観。




Fig. 2. $^{10}\text{C} + ^4\text{He}$ の散乱事象




Fig. 3. ^{10}C とクエンチガスとの散乱事象

Table I. 従来型の解析による画像識別結果

index	(%)
Accuracy	89
Efficiency	94
Purity	84
Jaccard	80

Table II. 評価指標における変数の意味

		Judged by analysis	
		Signal	Background
Eye-scanned	Signal	SS	SB
	Background	BS	BB

3. Conventional analysis method

従来は、MAIKo TPC から得られるデータから背景事象の除去を Hough 変換による飛跡抽出アルゴリズムを用いて行ってきた。Hough 変換とは画像から直線を抽出する方法の 1 つである。Hough 変換を行うことで画像は、原点からの距離 (r) と傾き (θ) の 2 つの軸を持つパラメータ空間に変換される (Fig. ??)。このパラメータ空間において複数の曲線が交わる点が元の画像における直線に対応する。交点を特定することで元の画像の中から直線を抽出することができる。抽出した直線に沿って端点を探すことで、画像に含まれる直線の方法や長さなどを決定することができる。これらの情報に対して多くの条件を課すことで画像の識別を行う。この条件には多くのパラメータを必要とし、分岐条件も複雑なものとなる。そのため、パラメータを最適化や画像識別に多くの時間を必要とする。

最適化を行ったあとの画像識別の結果を Table I に示す。最適化には 100 CPU を使用して約 1 日かかり、その後の識別には 1 イベントあたり 1 秒かかった。この手法による識別能力を評価するために、人間が判断した評価用データを用いて評価を行った。評価指標のそれぞれの定義は以下の通りである。また、各変数の意味は Table II の通りである。

$$\text{Accuracy} = \frac{SS + BB}{SS + SB + BS + BB} \quad (1)$$

$$\text{Efficiency} = \frac{SS}{SS + SB} \quad (2)$$

$$\text{Purity} = \frac{SS}{SS + BS} \quad (3)$$

$$\text{Jaccard} = \frac{SS}{SS + SB + BS} \quad (4)$$

4. New analysis method

従来手法では識別に複雑な分岐条件が必要になるなどの問題点があった。そこで、我々は近年注目されているニューラルネットワークを用いることで、これらの問題点克服した新しい解析方法の開発を試みた。ニューラルネットワークを用いることで、離れた点の関係や直線の位置、角度などの従来の解析手法ではまとめて扱うことの難しい多くの特徴量を同時に考慮した画像識別が可能になると期待される。また、ニューラルネットワークは一度構築するとその後は短時間で画像識別を行うことができる。このようなニューラルネットワークの特徴を活かすことで、従来のアルゴリズムでは実現が難しかった高い精度と短い識別時間を実現することが可能である。

MAIKo TPC から得られるデータが画像であるため、画像認識に有用である Convolutional Neural Network (CNN) を用いた。CNN とはネットワーク内に畳み込み層を有するネットワーク構造である。解析には事象の選別と情報の抽出の2つがあるため、2種類のニューラルネットワークを用いて解析を行った。データの選別を行うニューラルネットワークの構造は Fig. 4、画像から情報を抽出するニューラルネットワークの構造は Fig. 5 の通りである。




Fig. 4. データの選別を行うためのニューラルネットワーク

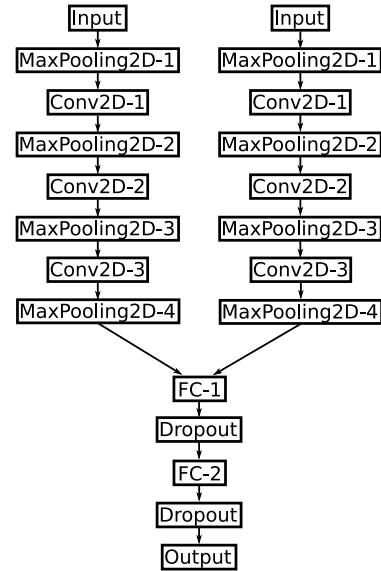


Fig. 5. 画像から情報を抽出するためのニューラルネットワーク

選別のためのニューラルネットワークは、MAIKo TPC から得られる2つの平面に射影された飛跡を入力し、その事象が標的と散乱した事象である確率を出力する。出力された確率がある値以上である場合にその事象を標的と散乱した事象であると判断する。このネットワークは16層からなり、2入力1出力の形をしている。側面に射影した飛跡とビーム方向に射影した飛跡とは画像の持つ意味が異なるため、2つの入力が別れた構造を持つネットワークを構築した。人間が判断したデータを用いて、学習および評価を行った。学習には2,700 events、評価には300 eventsを使用した。

情報を抽出するためのネットワークは、MAIKo TPC から得られる2つの平面に射影された飛跡を入力し、散乱が起こった座標と反跳した ^4He が停止した座標を出力する。学習を効率的に行うために、出力される座標は各軸が0–1の範囲になるように規格化した座標系で得られる。このネットワークは21層からなり、2入力1出力の形をしている。教師データには従来手法で決定した座標を用いた。学習には3,012 events、評価には1,554 eventsを使用した。

学習環境は以下の通りである。

- Intel Core i7
- Nvidia GeForce GTX 1080Ti
- Ubuntu 18.04 LTS
- Keras + TensorFlow

5. Result

選別のためのニューラルネットワークは、2,700 events に対して 200 回学習を行った。学習にはおよそ 26 分、その後の推測にはおよそ 1 秒かかった。学習後の識別能力および学習過程を Table III、Fig. 6 に示す。従来の手法と比較してすべての指標においてより高精度に選別が可能となった。また、パラメータチューニングおよび選別に要する時間も大きく短縮することができた。

Table III. 新手法の識別能力

index	Neural network (%)	Hough (%)
Accuracy	96	89
Efficiency	98	94
Purity	94	84
Jaccard	93	80




Fig. 6. 識別のためのニューラルネットワークの学習過程

座標の決定のためのニューラルネットワークは、3,012 events に対して 500 回学習を行った。学習にはおよそ 270 分、その後の推測にはおよそ 2 秒かかった。学習後にニューラルネットワークが予測した座標と従来手法によって決定した座標の比較を Fig. 7 に示す。学習過程を Fig. ?? に示す。従来手法の精度を維持しつつ、従来の手法と比較してパラメータチューニングおよび情報の抽出にかかる時間を短縮することができた。




Fig. 7. ニューラルネットワークによって決定した座標と Hough 変換によって決定した座標との比較




Fig. 8. 座標決定のためのニューラルネットワークの学習過程

6. Conclusion

従来の Hough 変換を用いた画像識別アルゴリズムに変わる、ニューラルネットワークを用いた新手法の開発を行った。新手法は従来のものよりも高速かつ高精度に画像を識別することが可能となった。また、飛跡情報の抽出については従来の精度を保ちつつ、高速に行うことが可能となった。ニューラルネットワークを用いた解析手法は TPC の解析に有用であることがわかった。

References

- [1] A. Ochi, T. Nagayoshi, T. Tanimori, T. Nagae, and M. Nakamura Nuclear Instruments and Methods in Physics Research A **471** 264 (2001)
- [2] T. Furuno, T. Kawabata, H. Ong, S. Adachi, Y. Ayyad, T. Baba, Y. Fujikawa, T. Hashimoto, K. Inaba, Y. Ishii, S. Kabuki, H. Kubo, Y. Matsuda, Y. Matsuoka, T. Mizumoto, T. Morimoto, M. Murata, T. Sawano, T. Suzuki, A. Takada, J. Tanaka, I. Tanihata, T. Tanimori, D. Tran, M-, Tsumura, and H. Watanabe Nuclear Instruments and Methods in Physics Research A **908** 215 (2018)
- [3] A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas, O. Vinyals, P. Warden, M. Wattenberg, M. Wicke, Y. Yu, and X. Zheng, (2015). <https://tensorflow.org>
- [4] F. Chollet, et al. (2015). <https://keras.io>