

# New analysis method of TPC data using neural network

Takanobu Doi<sup>1</sup>, Takahiro KAWABATA<sup>2</sup>, Tatsuya FURUNO<sup>3</sup>, Yuki FUJIKAWA<sup>1</sup>, Kento INABA<sup>1</sup>, Motoki MURATA<sup>3</sup>, Shintaro OKAMOTO<sup>1</sup> and Akane SAKAUE<sup>1</sup>

<sup>1</sup>Department of Physics, Kyoto University, Kyoto, Kyoto 606-8502, Japan

<sup>2</sup>Department of Physics, Osaka University, Toyonaka, Osaka 540-0043, Japan

<sup>3</sup>Research Center for Nuclear Physics, Osaka University, Ibaraki, Osaka 567-0047, Japan

E-mail: doi.takanobu.68x@st.kyoto-u.ac.jp

(Received 2019/8/31)


In the experiments with TPC, we can detect tracks. A 3-dimensional track is projected into 2-dimensional planes. It is necessary to analyze 2-dimensional image data from TPC. Conventionally, the analysis is used Hough transformation. This analysis requires a lot of efforts. These days, neural networks are attracting attention. In this work, we develop new analysis method using neural networks. By using new method, analysis can be performed faster than the conventional method.

**KEYWORDS:** neural networks, time projection chamber (TPC), active target, MAIKo TPC

## 1. Introduction

These days, Time Projection Chamber (TPC) is widely used to detect tracks of charged particles. We developed Mu-PIC based Active target for Inverse Kinematics. (MAIKo) TPC [2] using Micro Pixel Chamber ( $\mu$ -PIC) [1] for unstable nuclei experiments. Figure 1 shows the overview of MAIKo TPC. A detection gas is filled in TPC. When charged particles pass through the gas, electrons emitted. The electrons are drifted in the direction (downer arrow) of the readout surface by a drift electric field (upper arrow) and the tracks are detected. The  $\mu$ -PIC has 256 of anode strips and cathode strips which are arranged orthogonally. These strips are aligned at 400-um intervals. Anode strips are parallel to x-axis in Fig. 1 and cathode strips are parallel to z-axis. The signals induced by the drifted electron are read out through the anode and cathode strips which provide the 2-dimensional position (x-axis and z-axis) of the particle tracks. The vertical position (y-axis) of the tracks are determined from the drift time of the electrons. The 3-dimensional tracks are reconstructed from x, y, z-coordinates.

MAIKo TPC is the active target that a detection gas is used for a target gas. By using the active target, incident particles scatter with target particles in the detector. It is possible to detect low energy particles with a large solid angle. He or H<sub>2</sub> that is widely used for a target gas has low discharge resistance. Normally, CO<sub>2</sub> or iso-butane that has high discharge resistance is used for a quench gas and mixed with target gases. The events that incident particles are scattered with quench gases are background events. The elastic and inelastic alpha scatterings on <sup>10</sup>C were measured with MAIKo



**Fig. 1.** MAIKo TPC の概観

TPC at Research Center for Nuclear Physics, Osaka University (RCNP). In this experiment, He (96%) was used as target and CO<sub>2</sub> (4%) was used as quench gas.

The track of charged particle is projected into a plane that is perpendicular to anode strips (anode image) and a plane that is perpendicular to cathode strips (cathode image). MAIKo TPC outputs two images by one event.  $\mu$ -PIC has 256 anode strips and 256 cathode strips, and measure waveform by 1,024 samples in 100 MHz. The resolution of an image from MAIKo TPC is  $256 \times 1,024$ . Figures 2 and 3 are examples of measured data at RCNP. Figure 2 is the event that a incident particle scatter with He and Fig. 3 is the event that a incident particle scatter with quench gas.

In a scattering experiment, it is necessary to determine the energy and emission angle of the scattering particles. The energy is determined from the length of a track. The emission angle is determined from tracks of the incident particle and the scattering particle. To extract the information of tracks, there are two steps.

- Select events scattered with target and background events.
- Extract the length and the emission angle from images.




Fig. 2.  $^{10}\text{C} + ^4\text{He}$  の散乱事象




Fig. 3.  $^{10}\text{C}$  とクエンチガスとの散乱事象

There are a lot of efforts to select events and extract information of tracks. So, we developed faster analysis method using neural networks that are attracted attention in image recognition.

## 2. Conventional analysis method

従来は、得られたデータから背景事象の除去を行うために、画像中の直線を抽出する手法の1つである Hough 変換を用いたアルゴリズムによって行ってきた。In the Hough transformation, a hit pixel in the image at  $(x_i, y_i)$  is transformed into a curved line in the  $(\theta, r)$  parameter space (Hough space) according to Eq. (1).

$$r = x_i \cos \theta + y_i \sin \theta. \quad (1)$$

A point at  $(\theta_i, r_i)$  in the Hough space specify a straight line in the image as given by Eq. (2).

$$y = -\frac{x}{\tan \theta_j} + \frac{r_j}{\sin \theta_j}. \quad (2)$$

When the pixels in the anode or cathode image lie on a straight line, their transformed curves intersect at one point at  $(\theta_j, r_j)$  in the Hough space. Thus, the intersection point in the Hough space gives the particle track according to Eq. (2).

抽出した直線の長さや角度、本数、配置に対して多くの条件を課すことによって、He との散乱事象を選別することが出来る。さらに、選別された事象における He の飛跡の長さや角度から、散乱角とエネルギーを決定することが出来る。しかし、事象選別に必要な条件には複雑

な分岐を必要とし、多くのパラメータを導入しなければならない。そのため、パラメータの最適化や画像識別に多くの時間を必要とする。

パラメータの最適化には 100 CPU を使用して約 1 日かかり、その後の画像識別には 1 event あたり 1 秒かかった。この手法による識別能力の評価には、画像データを人間が目で見えて散乱事象もしくは背景事象と判断した 3,000 イベントを評価用データとして用いて行った。全事象のうち、散乱事象または背景事象の区別を正しく判断することが出来た事象数の割合を正解率としたとき、この従来型の解析手法では 89% の正解率であった。

### 3. New analysis method

従来手法では識別に複雑な分岐条件や多くの計算機パワーが必要になるという問題点があった。そこで、我々は近年注目されているニューラルネットワークを用いることで、これらの問題点を克服する新しい解析方法の開発を試みた。ニューラルネットワークを用いることで、複雑な条件分岐を導入することなく、直線の位置、角度などの従来の解析手法ではまとめて扱うことの難しい多くの特徴量を同時に考慮した画像識別が可能になるかもしれない。また、ニューラルネットワークは一度構築するとその後は短時間で画像識別を行うことができる。このようなニューラルネットワークの特徴を活かすことで、従来のアルゴリズムでは実現が難しかった高い精度と短い識別時間を実現することが期待される。

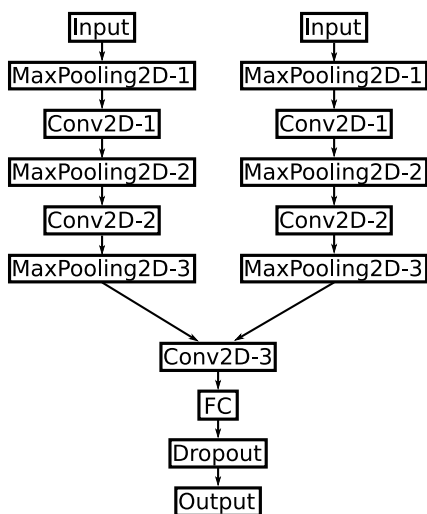


Fig. 4. データの選別を行うためのニューラルネットワーク

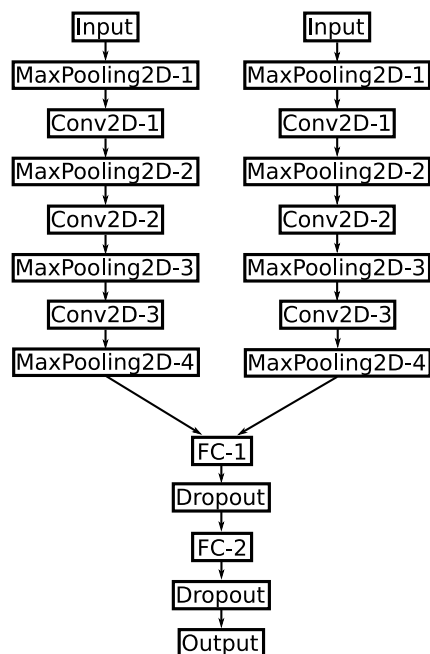


Fig. 5. 画像から情報を抽出するためのニューラルネットワーク

MAIKo TPC から得られるデータが画像であるため、画像認識に有用とされる Convolutional Neural Network (CNN) [5,6] を用いた。CNN とはネットワーク内に畳み込み層を有するネットワーク構造である。解析には事象の選別と飛跡情報の抽出の 2 つの段階があるため、2 種類のニューラルネットワークを用いて解析を行った。事象の選別を行うニューラルネットワークと画像から飛跡情報を抽出するニューラルネットワークの構造をそれぞれ Figs. 4 and 5 に示す。

事象選別のためのニューラルネットワークは、MAIKo TPC から得られる 2 つの画像を入力し、その事象が標的と散乱した事象である確率を出力する。出力された確率が 50% 以上である場合にその事象を標的と散乱した事象であるとした。anode image と cathode image では飛跡が異なる特徴を持つため、2 つの入力が別れた構造を持つネットワークを構築した。人間が判断

したデータを用いて、学習および評価を行った。学習には 2,700 events、評価には 300 events を使用した。

飛跡情報を抽出するためのネットワークには、事象選別のときと同様に MAIKo TPC から得られる 2 つの飛跡画像を入力し、散乱が起こった座標と反跳した  $^4\text{He}$  が停止した座標を出力させる。教師データには従来手法で決定した座標を用いた。学習には 3,012 events、評価には 1,554 events を使用した。

学習環境は Intel Core i7、Nvidia GeForce GTX 1080Ti、Ubuntu 18.04 LTS、TensorFlow [3]+Keras [4] を用いた。

## 4. Result

事象選別のためのニューラルネットワークは、2,700 events に対して 200 回学習を行った。学習にはおよそ 26 分、その後の推測には 300 events に対しておよそ 1 秒かかった。従来手法の評価に用いたのと同じ実験データのうち、300 events を用いて評価を行った結果、正解率は 96% であった。従来の手法と比較して高精度に事象選別を行うことが可能となった。また、パラメータチューニングおよび選別に要する時間も大きく短縮することができた。

座標の決定のためのニューラルネットワークは、3,012 events に対して 500 回学習を行った。学習にはおよそ 270 分、その後の推測には 1,554 events に対しておよそ 2 秒かかった。典型的なイベントにおいて、学習後にニューラルネットワークが予測した座標と従来手法によって決定した座標の比較を Fig. 6 に示す。学習データの散乱が起こった点を円、反跳粒子が停止した点を三角で示す。学習後に推論によって決定した散乱が起こった点を四角、反跳粒子が停止した点をひし形で示す。従来手法とニューラルネットワークを用いた手法のそれぞれで決定した座標は、ほぼ一致している。1,554 events に対して学習に用いた点とニューラルネットワークを用いて決定した点のズレは、平均二乗誤差で約 4 mm となった。従来の手法と比較してパラメータチューニングおよび情報の抽出にかかる時間を短縮することができた。




Fig. 6. ニューラルネットワークによって決定した座標と Hough 変換によって決定した座標との比較

## 5. Conclusion

従来の Hough 変換を用いた画像識別アルゴリズムに替わる、ニューラルネットワークを用いた新手法の開発を行った。新手法は従来のものよりも高速かつ高精度に事象の選別を行うことが可能となった。また、飛跡情報の抽出については従来の精度を保ちつつ、高速に行うことが可能となった。ニューラルネットワークを用いた解析手法は TPC の解析に有用であることがわかった。

## References

- [1] A. Ochi, T. Nagayoshi, T. Tanimori, T. Nagae, and M. Nakamura, Nucl. Instrum. Methods Phys. Res. A **471**, 264 (2001).
- [2] T. Furuno, T. Kawabata, H. Ong, S. Adachi, Y. Ayyad, T. Baba, Y. Fujikawa, T. Hashimoto, K. Inaba, Y. Ishii, S. Kabuki, H. Kubo, Y. Matsuda, Y. Matsuoka, T. Mizumoto, T. Morimoto, M. Murata, T. Sawano, T. Suzuki, A. Takada, J. Tanaka, I. Tanihata, T. Tanimori, D. Tran, M., Tsumura, and H. Watanabe, Nucl. Instrum. Methods Phys. Res. A **908**, 215 (2018).

- [3] A. Davis, J. Dean, M. Devin, S. Ghemawat, I. Goodfellow, A. Harp, G. Irving, M. Isard, Y. Jia, R. Jozefowicz, L. Kaiser, M. Kudlur, J. Levenberg, D. Mané, R. Monga, S. Moore, D. Murray, C. Olah, M. Schuster, J. Shlens, B. Steiner, I. Sutskever, K. Talwar, P. Tucker, V. Vanhoucke, V. Vasudevan, F. Viégas, O. Vinyals, P. Warden, M. Wattenberg, M. Wicke, Y. Yu, and X. Zheng, (2015). <https://tensorflow.org>
- [4] F. Chollet, et al., (2015). <https://keras.io>
- [5] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, Proceedings of the IEEE **86**, 11, 2278 (1998).
- [6] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton, Proceedings of the 25th International Conference on Neural Information Processing Systems - Volume **1**, 1097 (2012).